AI+X 중급 2차 프로젝트
중간점검발표

202310843 송예린
202310847 심영주
202310856 유세리

목차

1. 1번 파일_탐색적 데이터 분석
2. 2번 파일_데이터 전처리
3. 아이디어 도출

1. 1번 파일_탐색적 데이터 분석

1. 탐색적 데이터 분석(air)

```
# air_21 데이터의 head 확인
air_21.head()
```

	지역	망	측정소코드	측정소명	측정일시	SO2	CO	O3	NO2	PM10	PM25	주소
0	서울 종로구	도시대기	111123	종로구	2021100101	0.003	0.6	0.002	0.039	31.0	18.0	서울 종로구 종로35가길 19
1	서울 종로구	도시대기	111123	종로구	2021100102	0.003	0.6	0.002	0.035	27.0	16.0	서울 종로구 종로35가길 19
2	서울 종로구	도시대기	111123	종로구	2021100103	0.003	0.6	0.002	0.033	28.0	18.0	서울 종로구 종로35가길 19
3	서울 종로구	도시대기	111123	종로구	2021100104	0.003	0.6	0.002	0.030	26.0	16.0	서울 종로구 종로35가길 19
4	서울 종로구	도시대기	111123	종로구	2021100105	0.003	0.5	0.003	0.026	26.0	16.0	서울 종로구 종로35가길 19

air_21.shape: (8760, 12)

```
# air_22 데이터의 head 확인
air_22.head()
```

	지역	망	측정소코드	측정소명	측정일시	SO2	CO	O3	NO2	PM10	PM25	주소
0	서울 종로구	도시대기	111123	종로구	2022010101	0.003	0.4	0.026	0.016	23.0	12.0	서울 종로구 종로35가길 19
1	서울 종로구	도시대기	111123	종로구	2022010102	0.003	0.4	0.022	0.020	20.0	9.0	서울 종로구 종로35가길 19
2	서울 종로구	도시대기	111123	종로구	2022010103	0.003	0.5	0.014	0.028	20.0	9.0	서울 종로구 종로35가길 19
3	서울 종로구	도시대기	111123	종로구	2022010104	0.003	0.5	0.016	0.027	19.0	10.0	서울 종로구 종로35가길 19
4	서울 종로구	도시대기	111123	종로구	2022010105	0.003	0.5	0.005	0.040	24.0	11.0	서울 종로구 종로35가길 19

air_22.shape: (2160, 12)

1. 탐색적 데이터 분석(weather)

```
weather_21.head()
```

	지점	지점명	일시	기온(°C)	기온 QC플래그	강수량(mm)	강수량 QC플래그	풍속(m/s)	풍속 QC플래그	풍향(16방위)	...	최저운고(100m)	시정(10m)	지면상태(지면상태코드)	현상번호(국내식)	지면온도(°C)	지면온도 QC플래그	5cm 지중온도(°C)	10cm 지중온도(°C)	20cm 지중온도(°C)	30cm 지중온도(°C)
0	108	서울	2021-01-01 01:00	-8.7	NaN	NaN	NaN	2.4	NaN	270.0	...	NaN	2000	NaN	NaN	-6.9	NaN	-1.0	-0.8	0.3	1.6
1	108	서울	2021-01-01 02:00	-9.1	NaN	NaN	NaN	1.6	NaN	270.0	...	NaN	2000	NaN	NaN	-7.1	NaN	-1.1	-0.8	0.3	1.6
2	108	서울	2021-01-01 03:00	-9.3	NaN	NaN	NaN	1.1	NaN	250.0	...	NaN	2000	NaN	NaN	-7.3	NaN	-1.2	-0.9	0.3	1.6
3	108	서울	2021-01-01 04:00	-9.3	NaN	NaN	NaN	0.3	NaN	0.0	...	NaN	2000	NaN	NaN	-7.5	NaN	-1.3	-1.0	0.2	1.5
4	108	서울	2021-01-01 05:00	-9.7	NaN	NaN	NaN	1.9	NaN	20.0	...	NaN	2000	NaN	NaN	-7.6	NaN	-1.3	-1.0	0.2	1.5

weather_21.shape:(8759, 38)

```
weather_22.head()
```

	지점	지점명	일시	기온(°C)	기온 QC플래그	강수량(mm)	강수량 QC플래그	풍속(m/s)	풍속 QC플래그	풍향(16방위)	...	최저운고(100m)	시정(10m)	지면상태(지면상태코드)	현상번호(국내식)	지면온도(°C)	지면온도 QC플래그	5cm 지중온도(°C)	10cm 지중온도(°C)	20cm 지중온도(°C)	30cm 지중온도(°C)
0	108	서울	2022-01-01 00:00	-8.5	NaN	NaN	NaN	1.9	NaN	320	...	NaN	2000	NaN	NaN	-7.0	NaN	-1.0	-1.0	-0.2	1.0
1	108	서울	2022-01-01 01:00	-9.2	NaN	NaN	NaN	1.8	NaN	270	...	NaN	2000	NaN	NaN	-7.2	NaN	-1.1	-1.1	-0.2	1.0
2	108	서울	2022-01-01 02:00	-9.5	NaN	NaN	NaN	1.2	NaN	270	...	NaN	2000	NaN	NaN	-7.5	NaN	-1.3	-1.2	-0.2	1.0
3	108	서울	2022-01-01 03:00	-9.3	NaN	NaN	NaN	1.4	NaN	290	...	NaN	2000	NaN	NaN	-7.6	NaN	-1.4	-1.2	-0.2	1.0
4	108	서울	2022-01-01 04:00	-9.6	NaN	NaN	NaN	1.7	NaN	340	...	NaN	2000	NaN	NaN	-7.6	NaN	-1.4	-1.3	-0.3	1.0

weather_22.shape:(2160, 38)

1. 탐색적 데이터 분석(air 결측치)

air_21.shape: (8760, 12)

```
air_21.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 8760 entries, 0 to 8759
Data columns (total 12 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   지역      8760 non-null   object
 1   망       8760 non-null   object
 2   측정소코드   8760 non-null   int64
 3   측정소명    8760 non-null   object
 4   측정일시    8760 non-null   int64
 5   SO2     8648 non-null   float64
 6   CO      8680 non-null   float64
 7   O3      8663 non-null   float64
 8   NO2     8680 non-null   float64
 9   PM10    8655 non-null   float64
 10  PM25    8663 non-null   float64
 11  주소      8760 non-null   object
dtypes: float64(6), int64(2), object(4)
memory usage: 889.7+ KB
```

air_22.shape: (2160, 12)

```
air_22.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 2160 entries, 0 to 2159
Data columns (total 12 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   지역      2160 non-null   object
 1   망       2160 non-null   object
 2   측정소코드   2160 non-null   int64
 3   측정소명    2160 non-null   object
 4   측정일시    2160 non-null   int64
 5   SO2     2139 non-null   float64
 6   CO      2139 non-null   float64
 7   O3      2139 non-null   float64
 8   NO2     2139 non-null   float64
 9   PM10    2122 non-null   float64
 10  PM25    2135 non-null   float64
 11  주소      2160 non-null   object
dtypes: float64(6), int64(2), object(4)
memory usage: 219.4+ KB
```

1. 탐색적 데이터 분석(weather 결측치)

weather_21.shape:(8759, 38)

```
weather_21.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8759 entries, 0 to 8758
Data columns (total 38 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   지점              8759 non-null   int64
 1   지점명             8759 non-null   object
 2   일시              8759 non-null   object
 3   기온(°C)          8759 non-null   float64
 4   기온 QC플래그        0 non-null      float64
 5   강수량(mm)         949 non-null    float64
 6   강수량 QC플래그       1763 non-null   float64
 7   풍속(m/s)         8757 non-null   float64
 8   풍속 QC플래그        2 non-null      float64
 9   풍향(16방위)        8757 non-null   float64
 10  풍향 QC플래그        2 non-null      float64
 11  습도(%)           8759 non-null   int64
 12  습도 QC플래그        0 non-null      float64
 13  증기압(hPa)        8759 non-null   float64
 14  이슬점온도(°C)       8759 non-null   float64
 15  현지기압(hPa)       8759 non-null   float64
 16  현지기압 QC플래그      0 non-null      float64
 17  해면기압(hPa)       8759 non-null   float64
 18  해면기압 QC플래그      0 non-null      float64
 19  일조(hr)          4791 non-null   float64
 20  일조 QC플래그        3968 non-null   float64
 21  일사(MJ/m2)       4791 non-null   float64
 22  일사 QC플래그        3968 non-null   float64
 23  적설(cm)          379 non-null    float64
 24  3시간신적설(cm)      29 non-null     float64
 25  전운량(10분위)       8757 non-null   float64
 26  중하층운량(10분위)     8759 non-null   int64
 27  운형(운형약어)        4947 non-null   object
 28  최저운고(100m )     4547 non-null   float64
 29  시정(10m)         8759 non-null   int64
 30  지면상태(지면상태코드)    0 non-null      float64
 31  현상번호(국내식)       2125 non-null   float64
 32  지면온도(°C)        8754 non-null   float64
 33  지면온도 QC플래그      24 non-null     float64
 34  5cm 지중온도(°C)    8754 non-null   float64
 35  10cm 지중온도(°C)   8754 non-null   float64
 36  20cm 지중온도(°C)   8754 non-null   float64
 37  30cm 지중온도(°C)   8754 non-null   float64
dtypes: float64(31), int64(4), object(3)
memory usage: 2.5+ MB
```

weather_22.shape:(2160, 38)

```
weather_22.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2160 entries, 0 to 2159
Data columns (total 38 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   지점              2160 non-null   int64
 1   지점명             2160 non-null   object
 2   일시              2160 non-null   object
 3   기온(°C)          2160 non-null   float64
 4   기온 QC플래그        0 non-null      float64
 5   강수량(mm)         81 non-null     float64
 6   강수량 QC플래그       382 non-null    float64
 7   풍속(m/s)         2160 non-null   float64
 8   풍속 QC플래그        0 non-null      float64
 9   풍향(16방위)        2160 non-null   int64
 10  풍향 QC플래그        0 non-null      float64
 11  습도(%)           2160 non-null   int64
 12  습도 QC플래그        0 non-null      float64
 13  증기압(hPa)        2160 non-null   float64
 14  이슬점온도(°C)       2160 non-null   float64
 15  현지기압(hPa)       2160 non-null   float64
 16  현지기압 QC플래그      0 non-null      float64
 17  해면기압(hPa)       2160 non-null   float64
 18  해면기압 QC플래그      0 non-null      float64
 19  일조(hr)          1071 non-null   float64
 20  일조 QC플래그        1089 non-null   float64
 21  일사(MJ/m2)       1071 non-null   float64
 22  일사 QC플래그        1089 non-null   float64
 23  적설(cm)          140 non-null    float64
 24  3시간신적설(cm)      15 non-null     float64
 25  전운량(10분위)       2160 non-null   int64
 26  중하층운량(10분위)     2160 non-null   int64
 27  운형(운형약어)        939 non-null    object
 28  최저운고(100m )     743 non-null    float64
 29  시정(10m)         2160 non-null   int64
 30  지면상태(지면상태코드)    0 non-null      float64
 31  현상번호(국내식)       418 non-null    float64
 32  지면온도(°C)        2160 non-null   float64
 33  지면온도 QC플래그      7 non-null      float64
 34  5cm 지중온도(°C)    2160 non-null   float64
 35  10cm 지중온도(°C)   2160 non-null   float64
 36  20cm 지중온도(°C)   2160 non-null   float64
 37  30cm 지중온도(°C)   2160 non-null   float64
dtypes: float64(29), int64(6), object(3)
memory usage: 641.4+ KB
```

1. 탐색적 데이터 분석

info를 확인하는 과정에서
QC 칼럼들은 결측치가 대부분임을 확인

QC(Quality Control)

- <u>해당 측정값의 품질 또는 신뢰도</u>를 나타내는 메타데이터

QC 칼럼 삭제 여부 판단 기준

- 대부분 결측치-> 90% 이상 NaN이면 모델 입력값으로 사용 불가 => 삭제
- 특정 칼럼의 신뢰도 체크-> 강수량 같은 높은 QC 일 때만 유의미 => 일부 남기거나 다른 데이터와 병합

1. 탐색적 데이터 분석(air_21, 22- PM10)

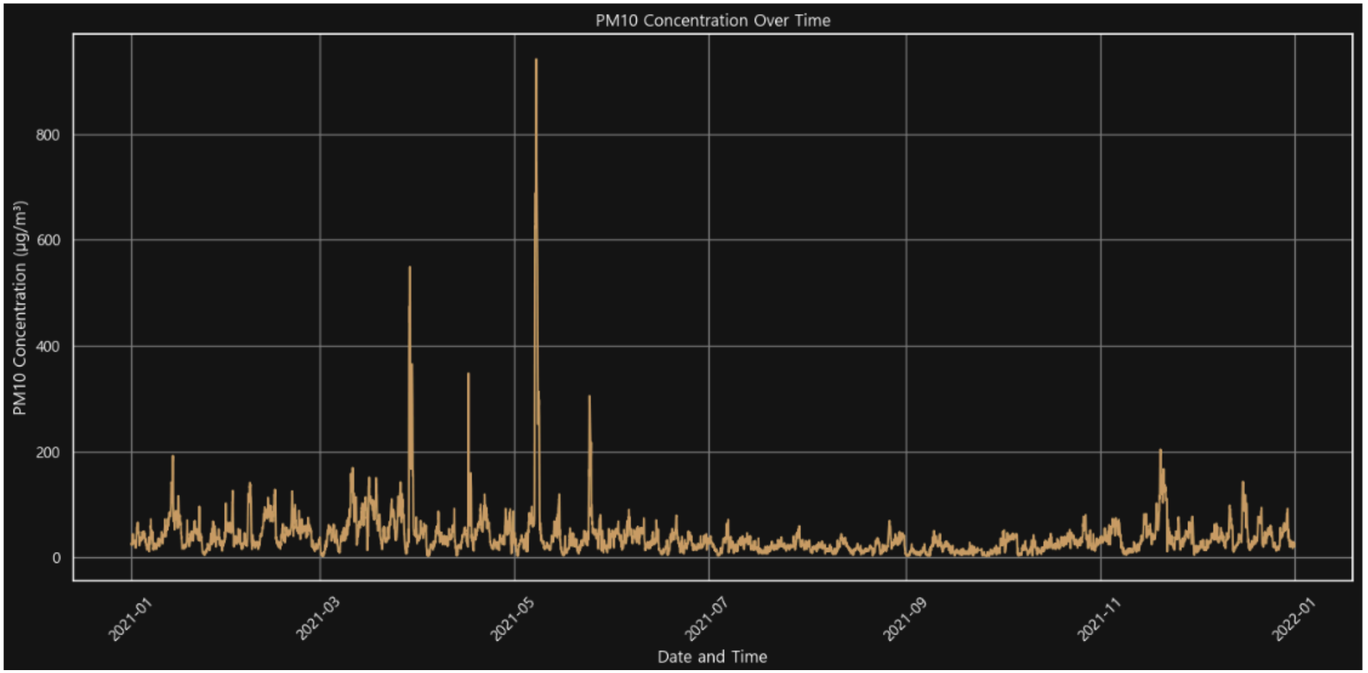

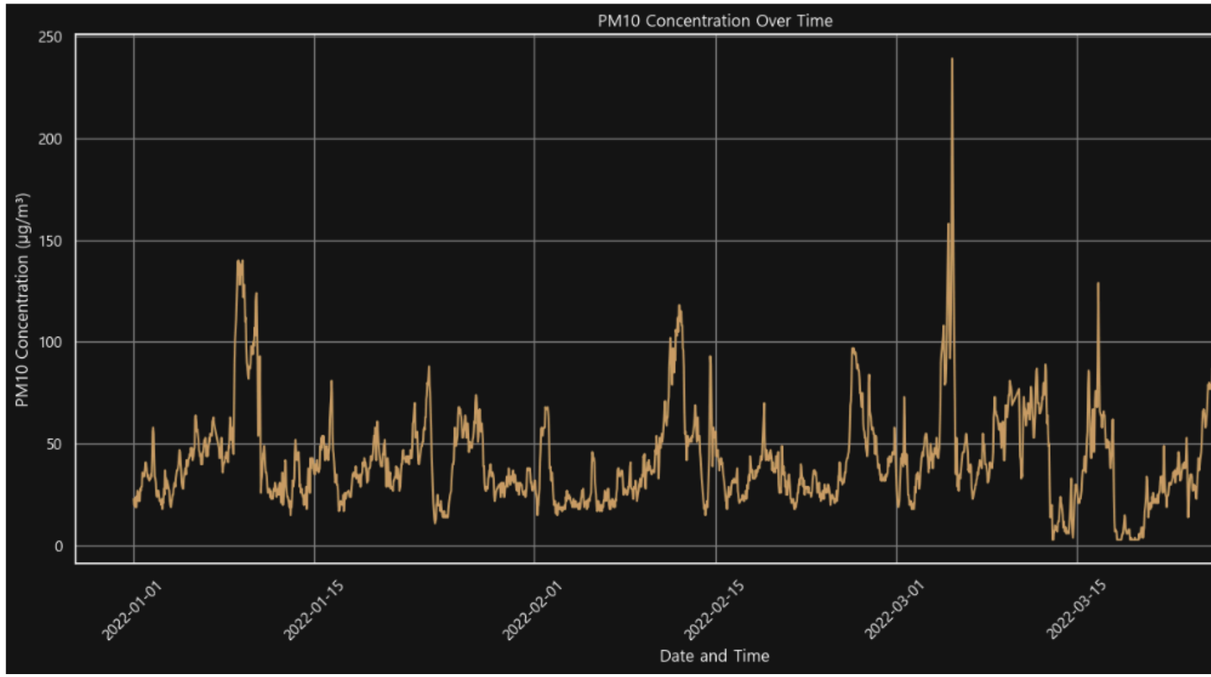

1. 탐색적 데이터 분석(air_21, 22- 다른 오염물질)

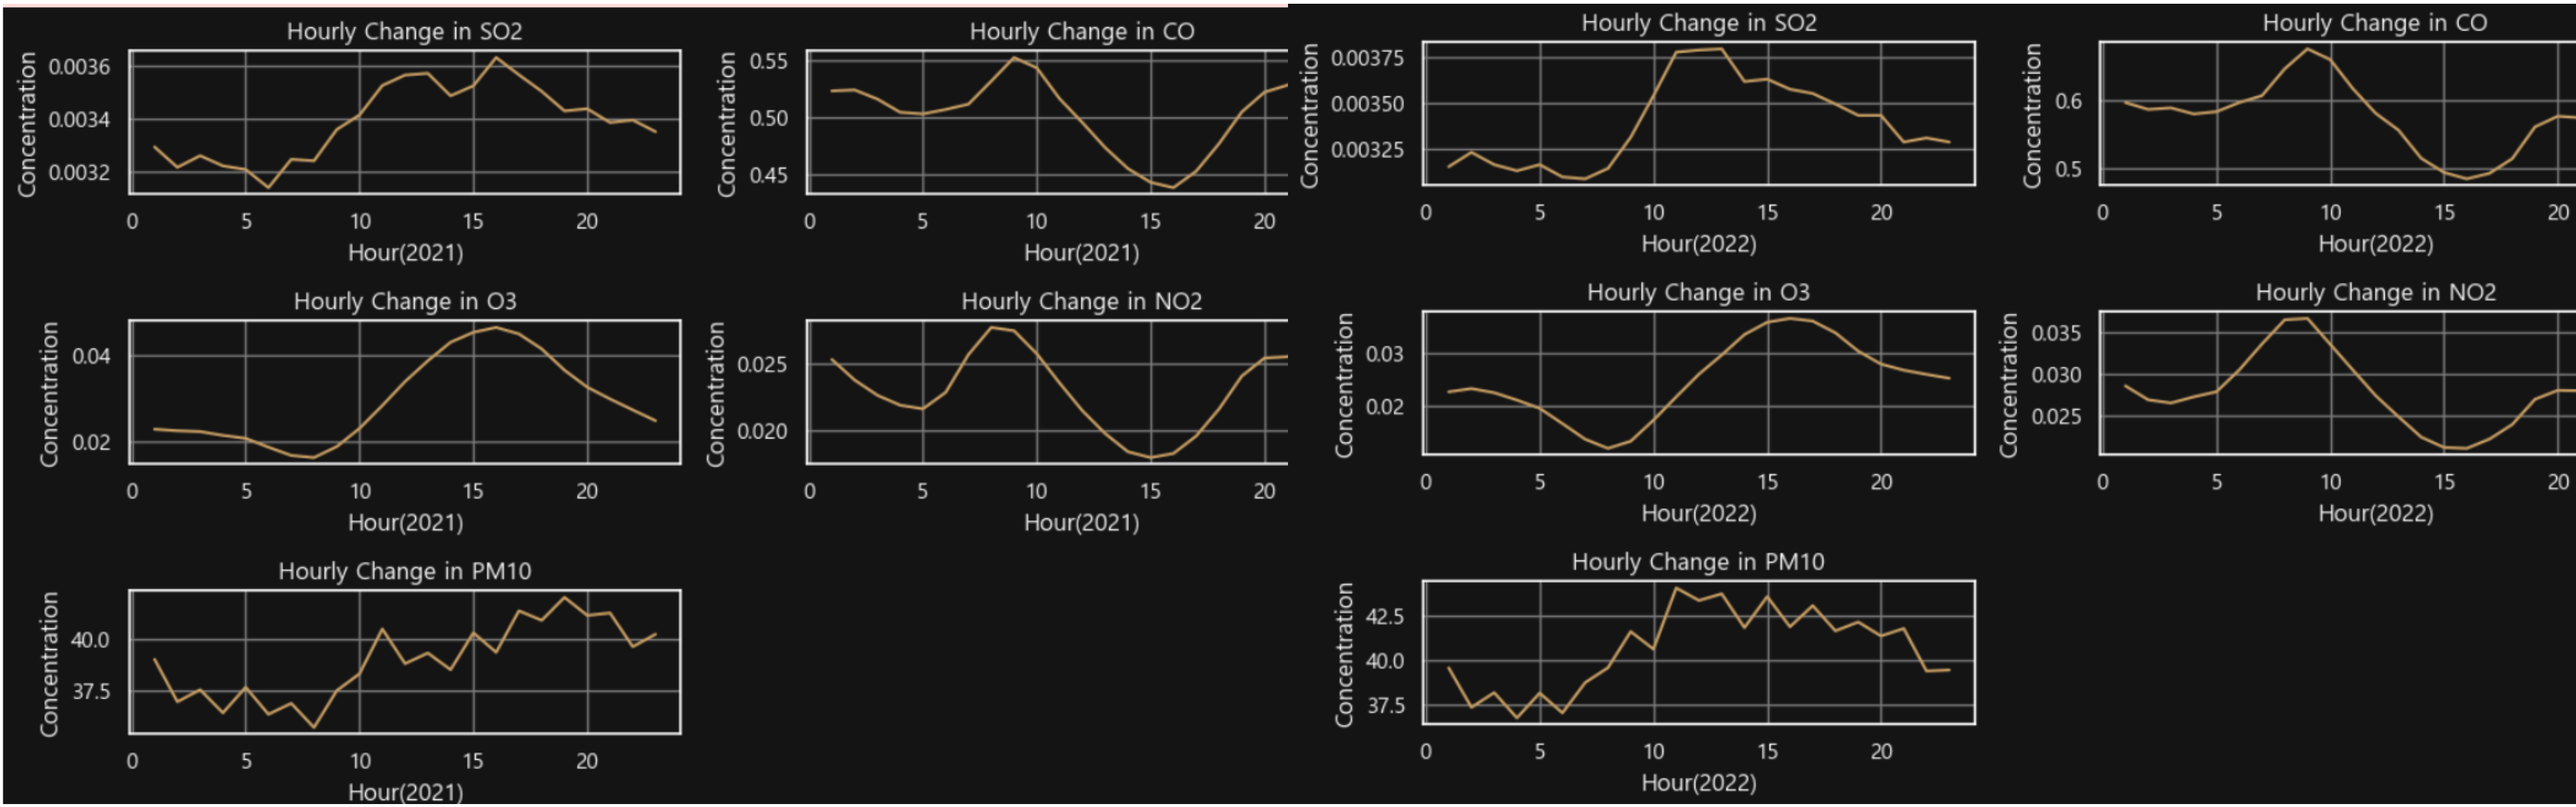

1. 탐색적 데이터 분석(air_21, 22- 다른 오염물질)

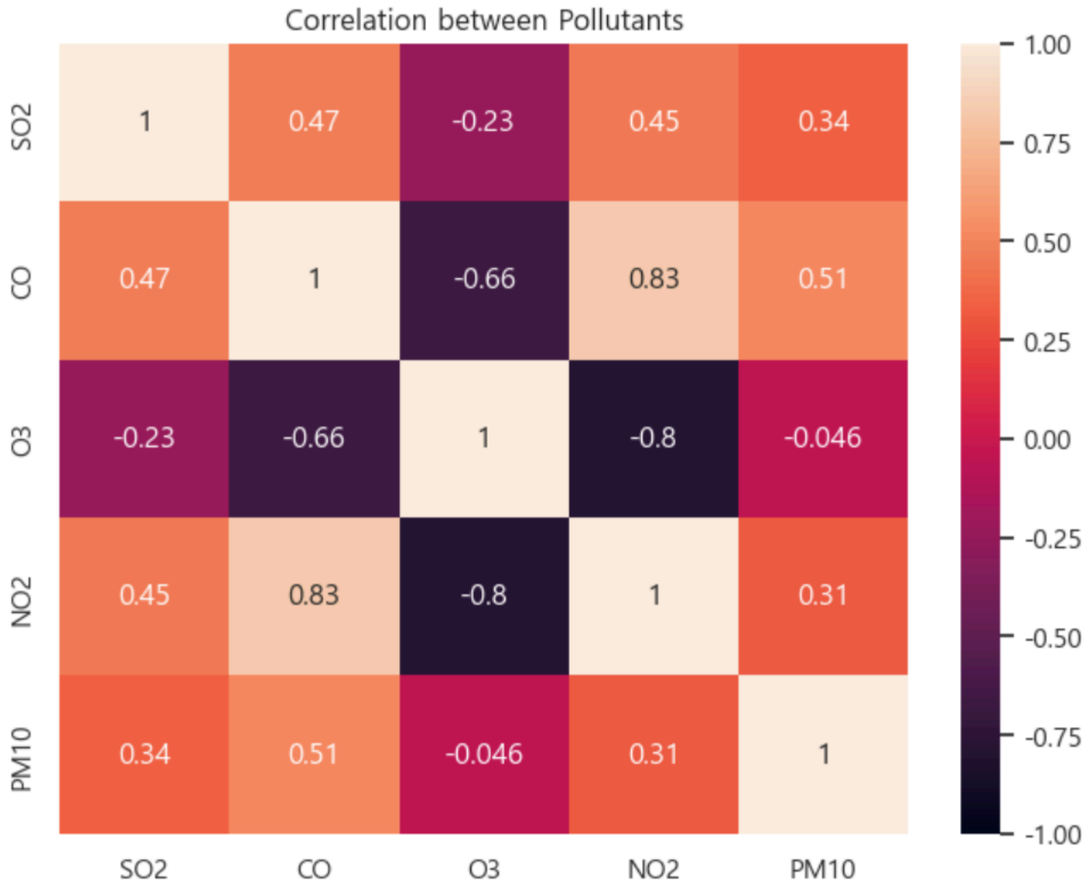

1. 탐색적 데이터 분석(air_21, 22)

1. 시간대별 **S02, O3, PM10**의 변화 형상이 비슷하다
2. 상관계수가 적으므로 **PM10에 큰 영향을 끼치지 못할 것**으로 예상

1. 탐색적 데이터 분석(weather_21, 22)

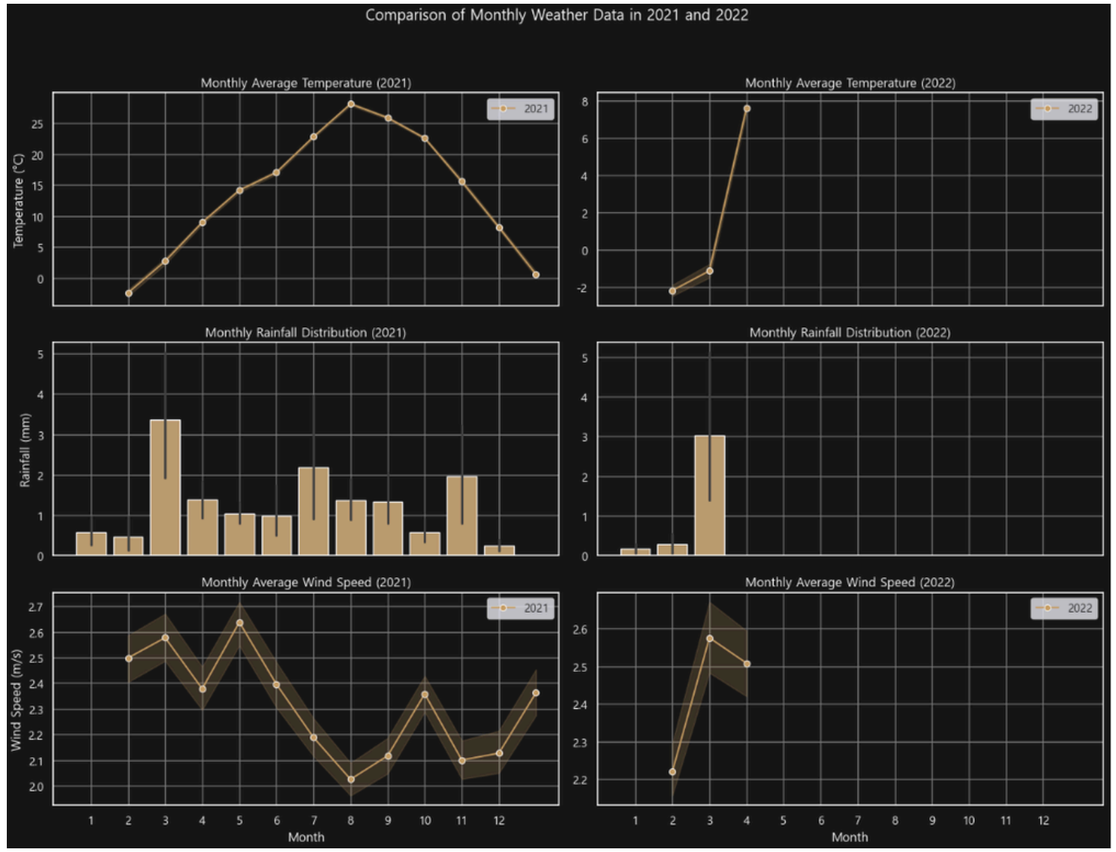

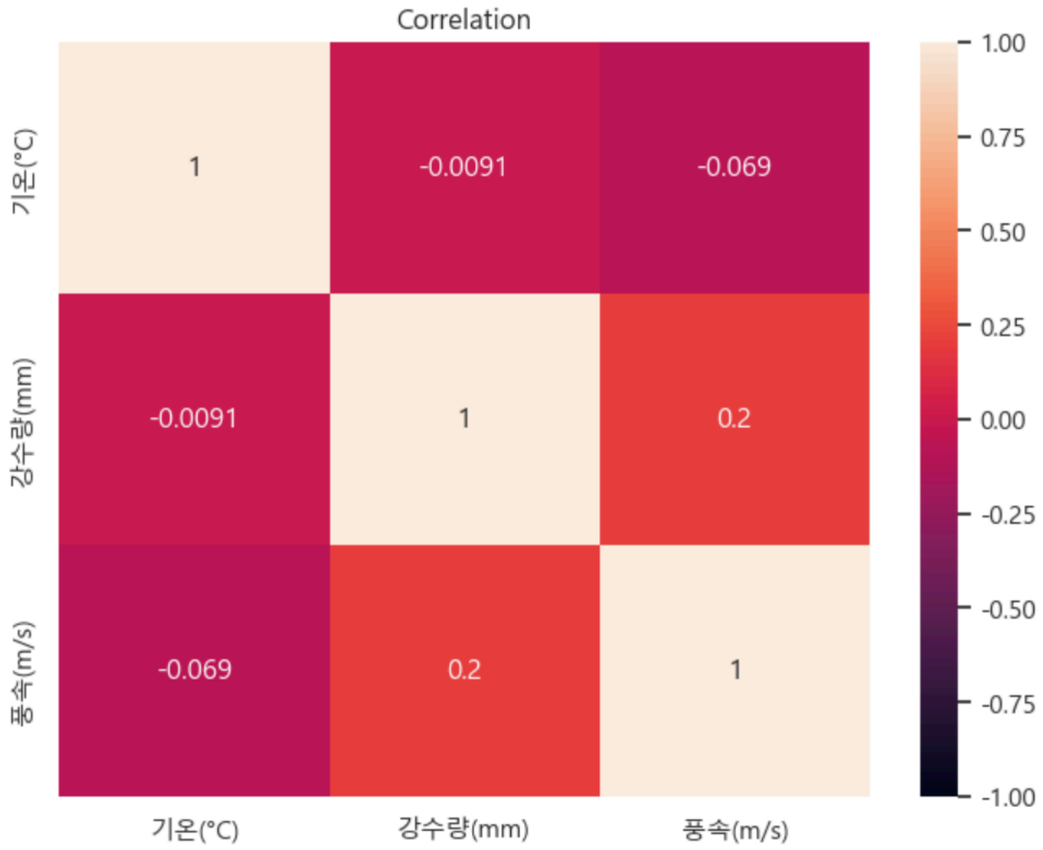

1. 탐색적 데이터 분석

1. 월별 기후 변화를 확인
2. **PM10 농도가 높은 날에 풍속이 높았음**을 알 수 있음
3. 봄철 중 **강수량이 제일 적은 5월에 PM10이 제일 높음**을 확인할 수 있음

2. 2번 파일_데이터 전처리

2.데이터 전처리

[2-2] weather_21, weather_22 의 '일시'를 활용하여 'time' 변수 생성

- weather_21, weather_22 의 '일시'를 활용하여 'time'변수 생성
- time 변수를 to_datetime으로 데이터 타입 변경

```
# 아래에 필요한 코드를 작성하고 결과를 확인합니다.
def add_weather_time_column(df):
    df['일시'] = df['일시'].astype(str)
    df['time'] = pd.to_datetime(df['일시'], format='%Y-%m-%d %H:%M')
    return df

weather_21 = add_weather_time_column(weather_21)
weather_22 = add_weather_time_column(weather_22)
#1시간 보정 없이 사용
```

```
# 확인 1: time 컬럼과 원본 '일시' 일부 확인
print(weather_21[['일시', 'time']].head())
print(weather_22[['일시', 'time']].head())

# 확인 2: time 컬럼에서 시간대가 0~23인지 확인
print(weather_21['time'].dt.hour.unique())
print(weather_22['time'].dt.hour.unique())
```

```
                  일시                time
0  2021-01-01 01:00 2021-01-01 01:00:00
1  2021-01-01 02:00 2021-01-01 02:00:00
2  2021-01-01 03:00 2021-01-01 03:00:00
3  2021-01-01 04:00 2021-01-01 04:00:00
4  2021-01-01 05:00 2021-01-01 05:00:00
                  일시                time
0  2022-01-01 00:00 2022-01-01 00:00:00
1  2022-01-01 01:00 2022-01-01 01:00:00
2  2022-01-01 02:00 2022-01-01 02:00:00
3  2022-01-01 03:00 2022-01-01 03:00:00
4  2022-01-01 04:00 2022-01-01 04:00:00
[ 1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19 20 21 22 23  0]
[ 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19 20 21 22 23]
```

1시부터 시작하는 데이터였기 때문에 1부터 나옴
(등장 순서 유지)

```
print(sorted(air_21['time'].dt.hour.unique()))
```

-> 0부터 정렬해줌

```
[0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23]
```

2.데이터 전처리

[2-2] weather_21, weather_22 의 '일시'를 활용하여 'time' 변수 생성

- weather_21, weather_22 의 '일시'를 활용하여 'time'변수 생성
- time 변수를 to_datetime으로 데이터 타입 변경

```
# 아래에 필요한 코드를 작성하고 결과를 확인합니다.
def add_weather_time_column(df):
    df['일시'] = df['일시'].astype(str)
    df['time'] = pd.to_datetime(df['일시'], format='%Y-%m-%d %H:%M')
    return df

weather_21 = add_weather_time_column(weather_21)
weather_22 = add_weather_time_column(weather_22)
#1시간 보정 없이 사용
```

일시와 time이 같음
(타입, 형식은 다르지만 같은 값)

```
df_21.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8759 entries, 0 to 8758
Data columns (total 52 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Unnamed: 0      8759 non-null   int64
 1   지역             8759 non-null   object
 2   망               8759 non-null   object
 3   측정소코드          8759 non-null   int64
 4   측정소명           8759 non-null   object
 5   측정일시           8759 non-null   object
 6   SO2             8647 non-null   float64
 7   CO              8679 non-null   float64
 8   O3              8662 non-null   float64
 9   NO2             8679 non-null   float64
 10  PM10            8654 non-null   float64
 11  PM25            8662 non-null   float64
 12  주소              8759 non-null   object
 13  time            8759 non-null   datetime64[ns]
 14  지점              8759 non-null   int64
 15  지점명             8759 non-null   object
 16  일시              8759 non-null   object
 17  기온(°C)          8759 non-null   float64
 18  기온 QC플래그        0 non-null      float64
```

```
#df_21.drop(columns=['일시'], inplace=True)
#일시 컬럼이 time과 중복 -> 문제시 제거 예정
```

-> 문제시 삭제 예정

2.데이터 전처리

[2-5] 변수들의 결측치 처리

```
# df_21, df_22의 결측치 확인
df_21.isnull().sum()
```

```
지역                    0
측정일시                  0
SO2                   112
CO                     80
O3                     97
NO2                    80
PM10                  105
PM25                   97
주소                    0
일시                    0
기온(°C)                0
강수량(mm)           7810
풍속(m/s)               2
풍향(16방위)              2
습도(%)                 0
증기압(hPa)               0
이슬점온도(°C)              0
현지기압(hPa)              0
해면기압(hPa)              0
일조(hr)             3968
일사(MJ/m2)          3968
전운량(10분위)              2
중하층운량(10분위)            0
시정(10m)               0
지면온도(°C)               5
5cm 지중온도(°C)          5
10cm 지중온도(°C)         5
20cm 지중온도(°C)         5
30cm 지중온도(°C)         5
dtype: int64
```

```
df_22.isnull().sum()
```

```
지역                    0
측정일시                  0
SO2                    21
CO                     21
O3                     21
NO2                    21
PM10                   38
PM25                   25
주소                    0
일시                    0
기온(°C)                0
강수량(mm)           2079
풍속(m/s)               0
풍향(16방위)              0
습도(%)                 0
증기압(hPa)               0
이슬점온도(°C)              0
현지기압(hPa)              0
해면기압(hPa)              0
일조(hr)             1089
일사(MJ/m2)          1089
전운량(10분위)              0
중하층운량(10분위)            0
시정(10m)               0
지면온도(°C)               0
5cm 지중온도(°C)          0
10cm 지중온도(°C)         0
20cm 지중온도(°C)         0
30cm 지중온도(°C)         0
dtype: int64
```

```
# df_21, df_22의 변수 중 '강수량(mm)'의 결측치를 처리
df_21['강수량(mm)'] = df_21['강수량(mm)'].fillna(0)
df_22['강수량(mm)'] = df_22['강수량(mm)'].fillna(0)
```

```
# df_21, df_22의 남은 결측치를 처리
df_21['일조(hr)'] = df_21['일조(hr)'].fillna(0)
df_22['일조(hr)'] = df_22['일조(hr)'].fillna(0)
```

```
df_21['일사(MJ/m2)'] = df_21['일사(MJ/m2)'].fillna(0)
df_22['일사(MJ/m2)'] = df_22['일사(MJ/m2)'].fillna(0)
```

```
# 평균 대체
df_21['풍속(m/s)'] = df_21['풍속(m/s)'].fillna(df_21['풍속(m/s)'].mean())
df_21['전운량(10분위)'] = df_21['전운량(10분위)'].fillna(df_21['전운량(10분위)'].median())

# 풍향은 최빈값 또는 앞값으로 보완
df_21['풍향(16방위)'] = df_21['풍향(16방위)'].fillna(df_21['풍향(16방위)'].mode()[0])
# 또는: df_21['풍향(16방위)'].fillna(method='ffill', inplace=True)
```

-> df_21의 결측값 처리

2.데이터 전처리

[2-8] train, test 데이터 분리 및 저장

```python
# 아래에 필요한 코드를 작성하고 결과를 확인합니다.(회귀모델의 데이터 셋 만들기)

train_x1 = df_21.drop(['PM10_1', 'time' , 'PM10', 'PM10_lag1'], axis=1)
train_y1 = df_21['PM10_1']
test_x1 = df_22.drop(['PM10_1', 'time' , 'PM10', 'PM10_lag1'], axis=1)
test_y1 = df_22['PM10_1']
```

```python
# 각각의 데이터프레임을 csv 파일로 저장 (train_x1.csv / train_y1.csv / test_x1.csv / test_y1.csv)

train_x1.to_csv('train_x1.csv', index = False)
train_y1.to_csv('train_y1.csv', index = False)
test_x1.to_csv('test_x1.csv', index = False)
test_y1.to_csv('test_y1.csv', index = False)
```

```python
# 아래에 필요한 코드를 작성하고 결과를 확인합니다.(시계열모델의 데이터 셋 만들기)

train_x2 = df_21.drop(['PM10_1', 'time'], axis=1)
train_y2 = df_21['PM10_1']
test_x2 = df_22.drop(['PM10_1', 'time'], axis=1)
test_y2 = df_22['PM10_1']
```

```python
# 각각의 데이터프레임을 csv 파일로 저장 (train_x2.csv / train_y2.csv / test_x2.csv / test_y2.csv)

train_x2.to_csv('train_x2.csv', index = False)
train_y2.to_csv('train_y2.csv', index = False)
test_x2.to_csv('test_x2.csv', index = False)
test_y2.to_csv('test_y2.csv', index = False)
```

```
---------------------------------------------------------------------------
KeyError                                  Traceback (most recent call last)
Cell In[108], line 3
      1 # 아래에 필요한 코드를 작성하고 결과를 확인합니다.(회귀모델의 데이터 셋 만들기)
----> 3 train_x1 = df_21.drop(['PM10_1', 'time' , 'PM10', 'PM10_lag1'], axis=1)
      4 train_y1 = df_21['PM10_1']
      5 test_x1 = df_22.drop(['PM10_1', 'time' , 'PM10', 'PM10_lag1'], axis=1)
```

```
KeyError: "['time'] not found in axis"
```

-> 이미 time을 인덱스로 설정했기 때문에 df.drop(['time'], axis=1) 하면 컬럼에 없어서 오류

```python
# time 변수를 index로 세팅
df_21.set_index('time', inplace=True)
df_22.set_index('time', inplace=True)
```

```python
#-> 인덱스를 다시 칼럼으로 복원
df_21 = df_21.reset_index()
df_22 = df_22.reset_index()
```

3. 아이디어 도출

기상학적 상관요소 관점에서?

- 대기 안정도 지수 (Stability Index)
  - 기상청 수치예보자료에 존재
  - 활용: 대기 정체 상태 → 미세먼지 농도 축적 가능성 예측
- 기압차 기반 미세먼지 유입/배출 추정
  - 고기압이 정체되면 PM 농도 상승

감사합니다.